

# Data Mining

## Regras de Classificação

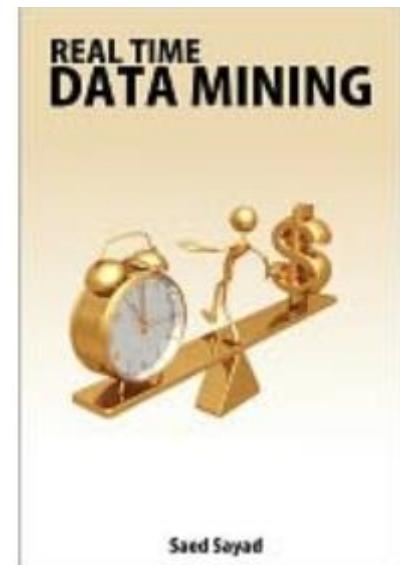
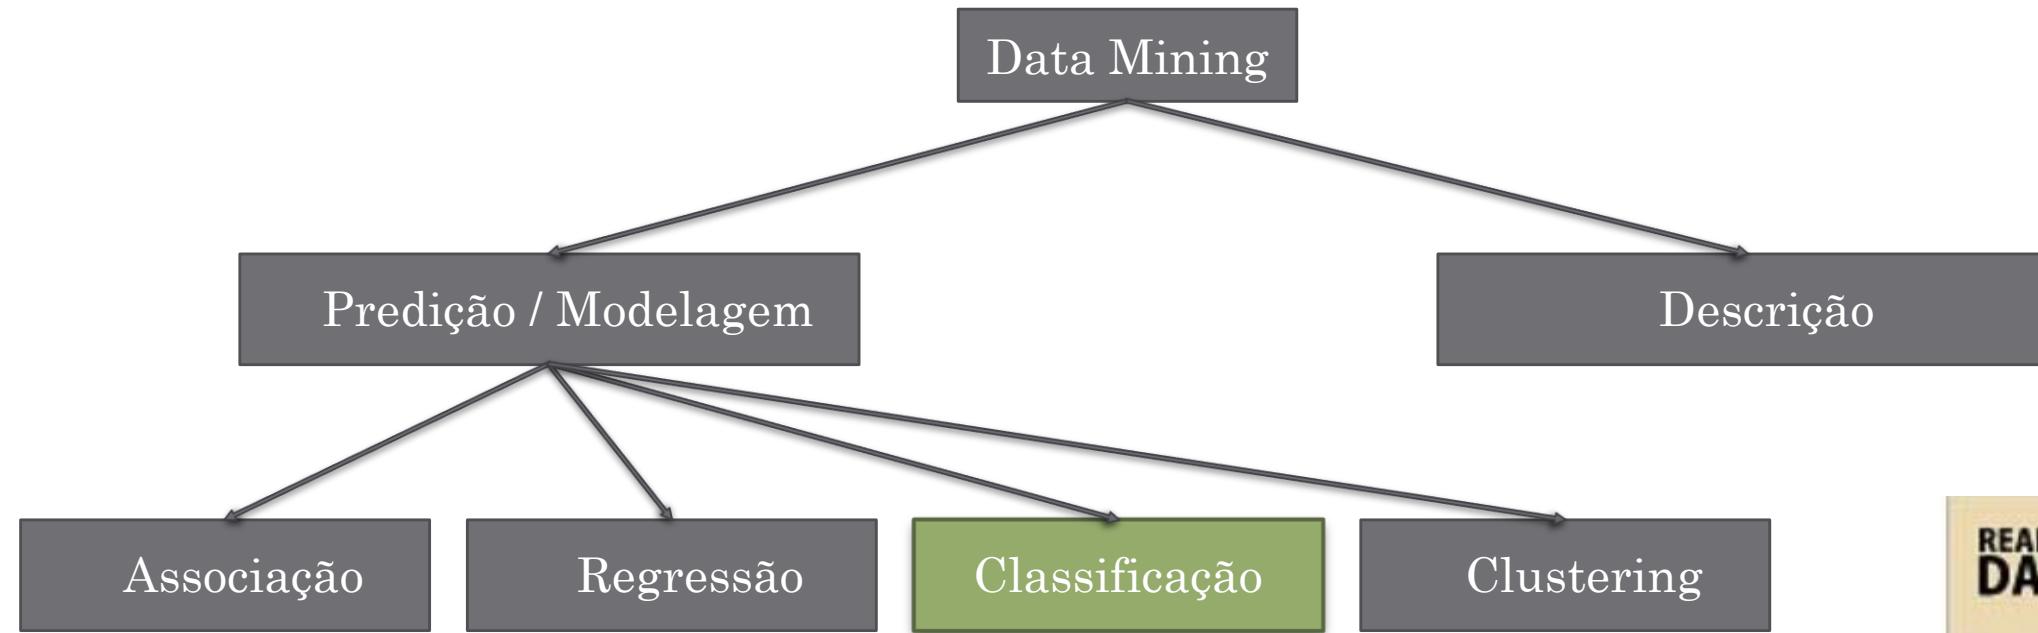
Prof. Dr. Joaquim Assunção

DEPARTAMENTO DE COMPUTAÇÃO APLICADA  
CENTRO DE TECNOLOGIA  
UFSM  
2018

[www.inf.ufsm.br/~joaquim](http://www.inf.ufsm.br/~joaquim)



# Mapa para Mineração de Dados\*

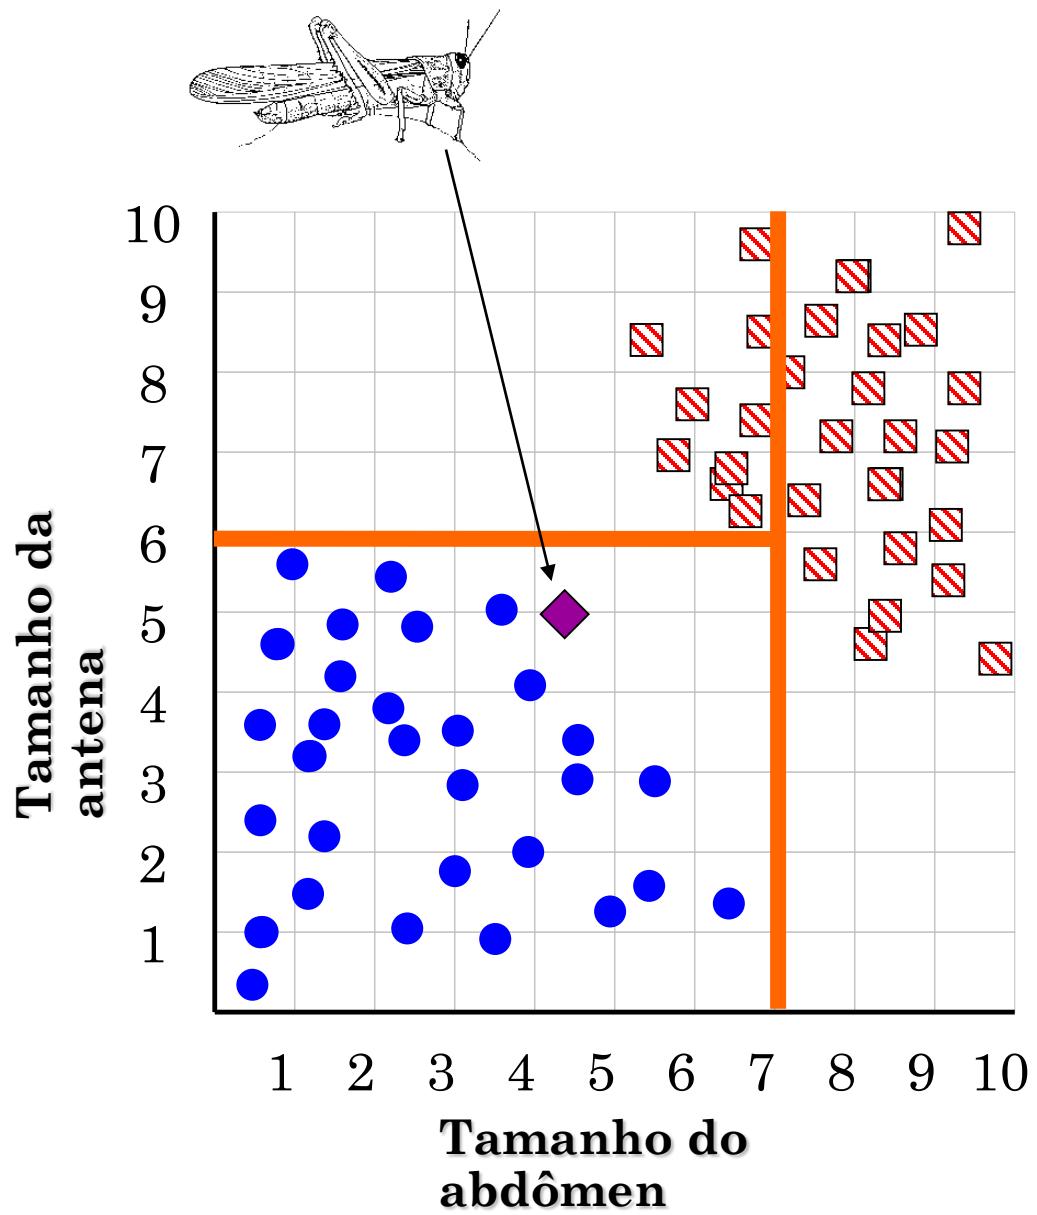


\*[http://www.saedsayad.com/data\\_mining\\_map.htm](http://www.saedsayad.com/data_mining_map.htm)

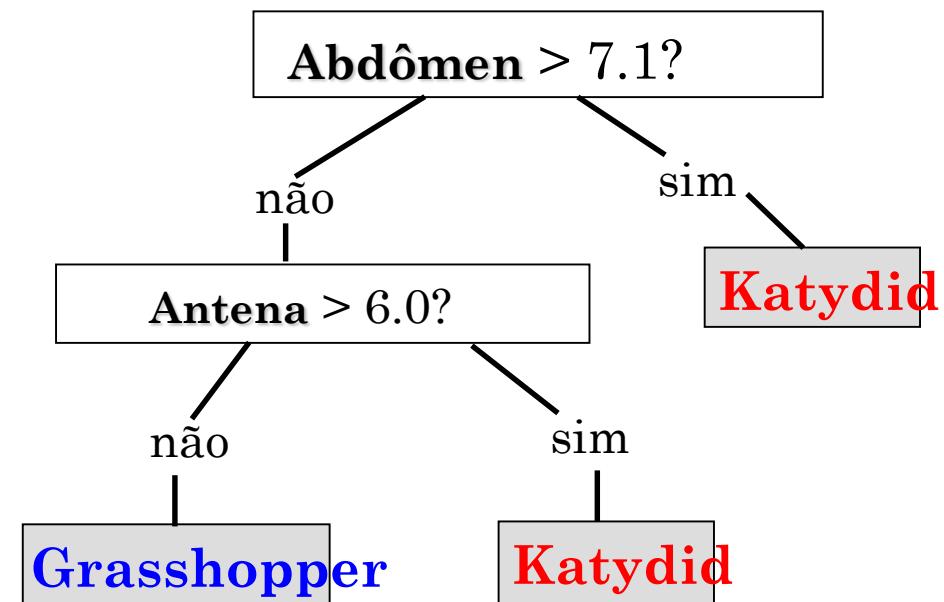
# Notas legais

- Este material foi cedido pelo Dr. Eamonn Keogh (University of California - Riverside, US) para as aulas de mineração de dados na UFSM.
- Tradução e adaptação: Dr. Joaquim Assunção.

# Decision Tree Classifier

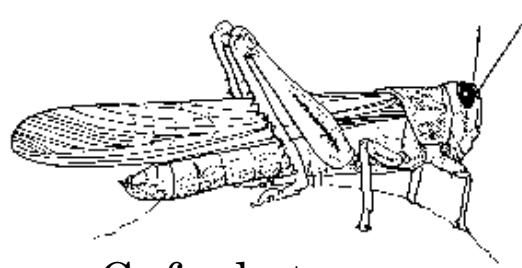


Ross Quinlan



**Antena é mais curta que o corpo?**

Yes



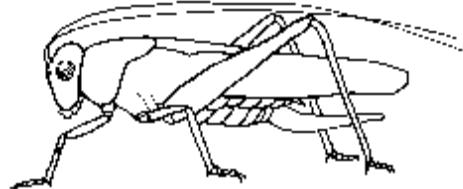
Gafanhoto

No

**3 Tarsi?**



Yes



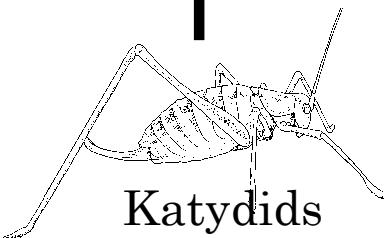
Grilo

No



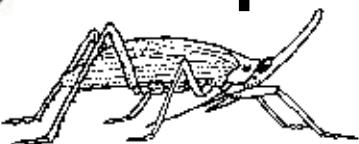
**Foretiba tem orelhas?**

Yes



Katydids

No



Grilo Camelo

# Uma árvore de decisão ...

- É uma estrutura de árvore do tipo fluxograma.
- Nό interno indica um teste em um atributo.
- Uma ramificação representa um resultado do teste.
- Nós de folha representam rótulos de classe ou distribuição de classe

# A geração da árvore de decisão consiste em duas fases

- Construção de árvores
  - No início, todos os exemplos de treinamento estão na raiz.
  - Exemplos de partição são recursivamente criados com base nos atributos selecionados.
- Poda de árvores
  - Identifique e remova ramificações que refletem ruído ou *outliers*.

# Como construir uma árvore



## Algoritmo base (abordagem gulosa)

- A árvore é construída de uma maneira recursiva por divisão e conquista, de cima para baixo.
- No início, todos os exemplos de treinamento estão na raiz.
  1. Atributos são categóricos (se forem de valor contínuos, podem ser discretizados com antecedência).
  2. Os exemplos são particionados recursivamente com base nos atributos selecionados.
  3. Os atributos de teste são selecionados com base em uma medida heurística ou estatística (por exemplo, ganho de informações).

# Como construir uma árvore



## Condições de parada

- Todas as amostras de um determinado nó pertencem à mesma classe.
- Não há atributos remanescentes para particionamento adicional - votação majoritária é empregada para classificar a folha.
- Não há amostras restantes.

# Como construir uma árvore



## Ganho de informação como critério de divisão

- Selecione o atributo com o maior ganho de informação (ganho de informação é a redução esperada na entropia).
- Suponha que existem duas classes, P e N
  - Deixe o conjunto de exemplos  $S$  conter  $p$  elementos da classe  $P$  e  $n$  elementos da classe  $N$
  - A quantidade de informação necessária para decidir se um exemplo arbitrário em  $S$  pertence a  $P$  ou  $N$  é definido como:

$$E(S) = -\frac{p}{p+n} \log_2 \left( \frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left( \frac{n}{p+n} \right)$$

# Como construir uma árvore



## Ganho de informação como critério de divisão

- Selecione o atributo com o maior ganho de informação (ganho de informação é a redução esperada na entropia).
- Suponha que existem duas classes, P e N
  - Deixe o conjunto de exemplos  $S$  conter  $p$  elementos da classe  $P$  e  $n$  elementos da classe  $N$
  - A quantidade de informação necessária para decidir se um exemplo arbitrário em  $S$  pertence a  $P$  ou  $N$  é definido como:

$$E(S) = -\frac{p}{p+n} \log_2 \left( \frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left( \frac{n}{p+n} \right)$$

...

Suponha que, usando o atributo  $A$ , um conjunto atual seja particionado em algum número de conjuntos filho

A informação de codificação que seria obtida pela ramificação em  $A$  →

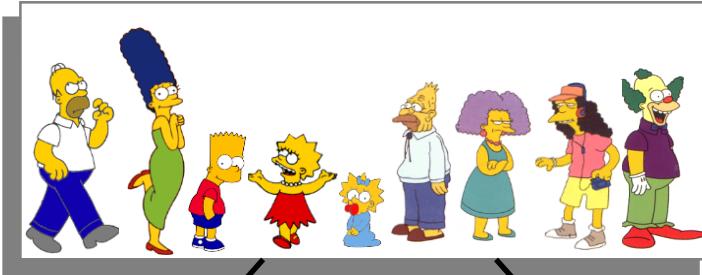
$$Gain(A) = E(\text{Current set}) - \sum E(\text{all child sets})$$

Nota: entropia está no mínimo se a coleção de objetos for uniforme.

# Exemplo

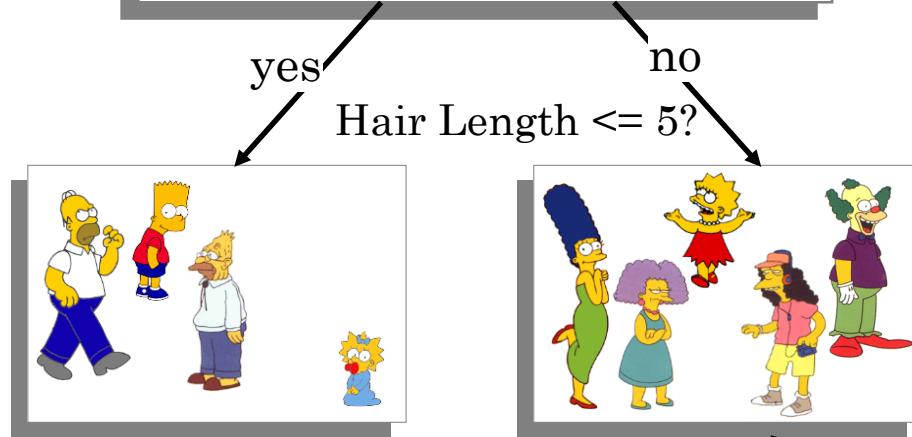
Person	Hair Length	Weight	Age	Class
 Homer	0"	250	36	M
 Marge	10"	150	34	F
 Bart	2"	90	10	M
 Lisa	6"	78	8	F
 Maggie	4"	20	1	F
 Abe	1"	170	70	M
 Selma	8"	160	41	F
 Otto	10"	180	38	M
 Krusty	6"	200	45	M

	Comic	8"	290	38	?
---	-------	----	-----	----	---



$$Entropy(S) = -\frac{p}{p+n} \log_2 \left( \frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left( \frac{n}{p+n} \right)$$

$$\begin{aligned}Entropy(4F, 5M) &= -(4/9)\log_2(4/9) - (5/9)\log_2(5/9) \\&= 0.9911\end{aligned}$$



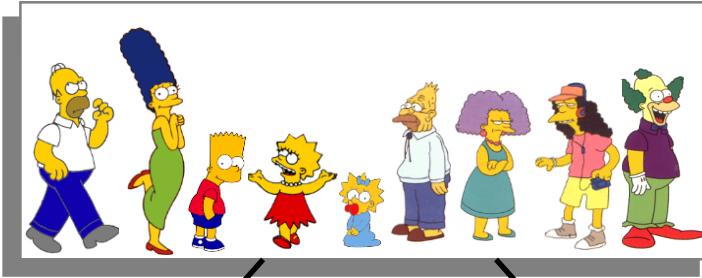
Vamos tentar divider  
em *Hair length*

$$\begin{aligned}Entropy(1F, 3M) &= -(1/4)\log_2(1/4) - (3/4)\log_2(3/4) \\&= 0.8113\end{aligned}$$

$$\begin{aligned}Entropy(3F, 2M) &= -(3/5)\log_2(3/5) - (2/5)\log_2(2/5) \\&= 0.9710\end{aligned}$$

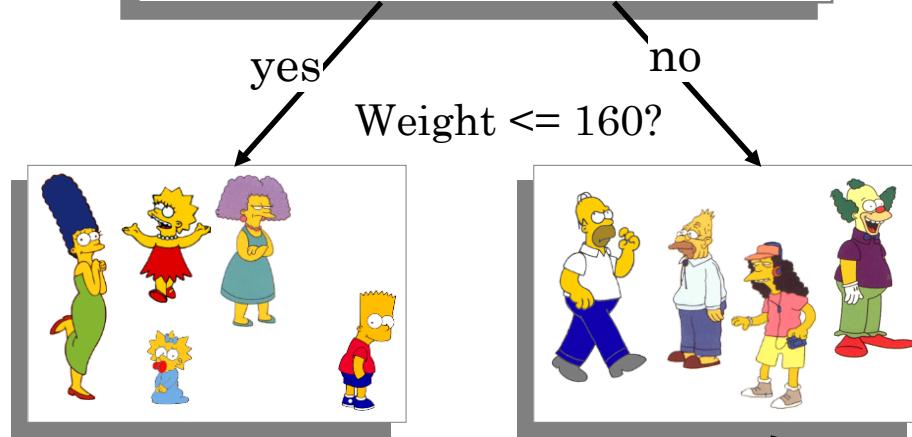
$$Gain(A) = E(Current\ set) - \sum E(all\ child\ sets)$$

$$\begin{aligned}Gain(\text{Hair Length} \leq 5) &= 0.9911 - (4/9 * 0.8113 + 5/9 * 0.9710) \\&= 0.0911\end{aligned}$$



$$Entropy(S) = -\frac{p}{p+n} \log_2 \left( \frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left( \frac{n}{p+n} \right)$$

$$\begin{aligned}Entropy(4F, 5M) &= -(4/9)\log_2(4/9) - (5/9)\log_2(5/9) \\&= 0.9911\end{aligned}$$



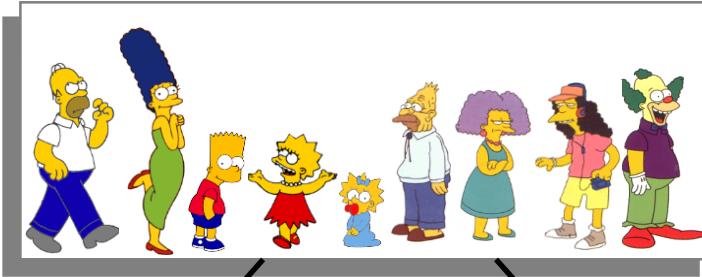
Vamos tentar divider  
em *Weight*

$$\begin{aligned}Entropy(4F, 1M) &= -(4/5)\log_2(4/5) - (1/5)\log_2(1/5) \\&= 0.7219\end{aligned}$$

$$\begin{aligned}Entropy(0F, 4M) &= -(0/4)\log_2(0/4) - (4/4)\log_2(4/4) \\&= 0\end{aligned}$$

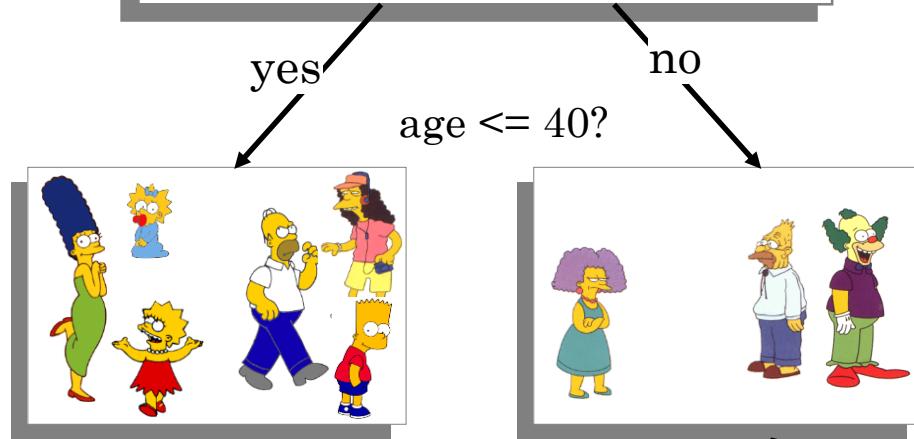
$$Gain(A) = E(Current\ set) - \sum E(all\ child\ sets)$$

$$Gain(\text{Weight} \leq 160) = 0.9911 - (5/9 * 0.7219 + 4/9 * 0) = 0.5900$$



$$Entropy(S) = -\frac{p}{p+n} \log_2 \left( \frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left( \frac{n}{p+n} \right)$$

$$\begin{aligned}Entropy(4F, 5M) &= -(4/9)\log_2(4/9) - (5/9)\log_2(5/9) \\&= 0.9911\end{aligned}$$



Vamos tentar divider  
em Age

$$\begin{aligned}Entropy(3F, 3M) &= -(3/6)\log_2(3/6) - (3/6)\log_2(3/6) \\&= 1\end{aligned}$$

$$\begin{aligned}Entropy(1F, 2M) &= -(1/3)\log_2(1/3) - (2/3)\log_2(2/3) \\&= 0.9183\end{aligned}$$

$$Gain(A) = E(�urrent set) - \sum E(all child sets)$$

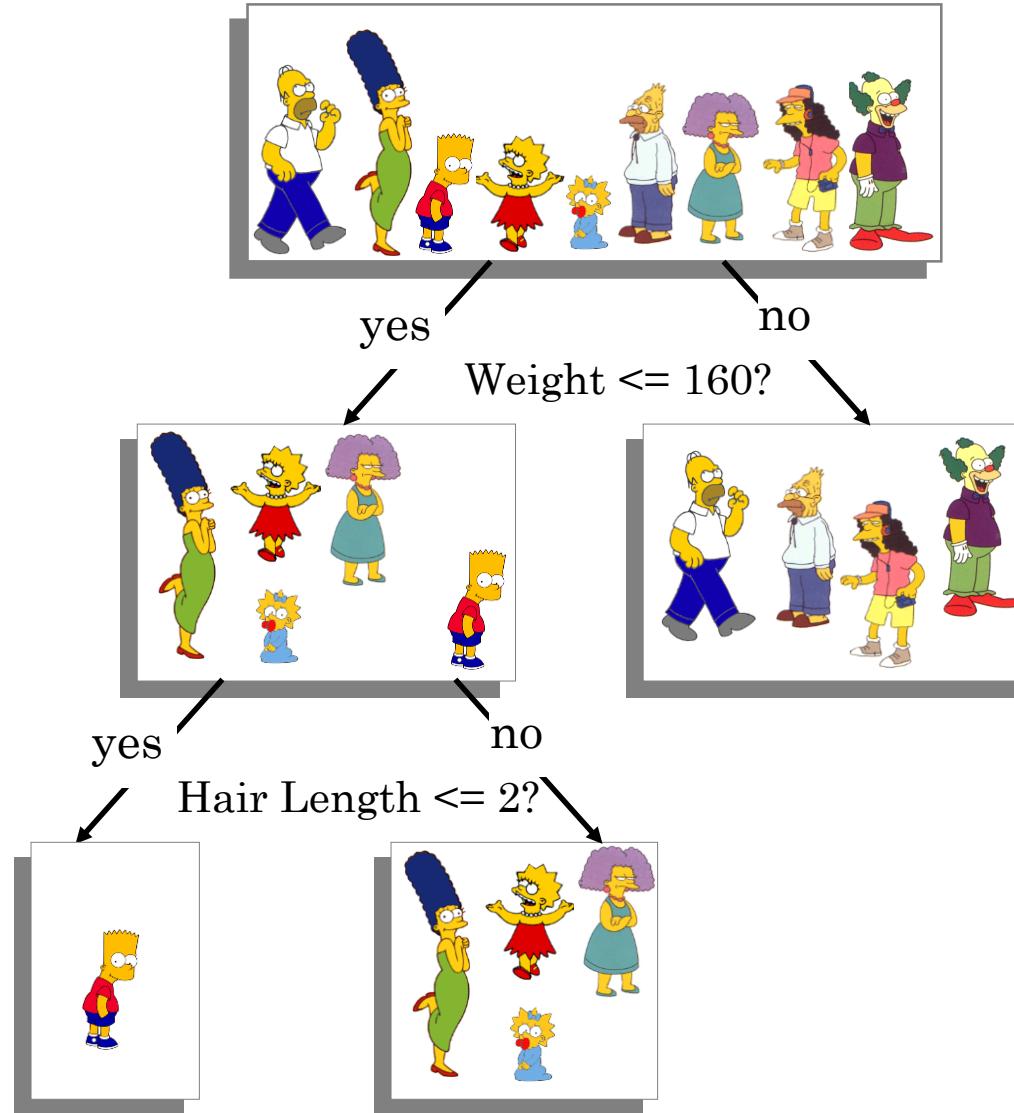
$$Gain(\text{Age} \leq 40) = 0.9911 - (6/9 * 1 + 3/9 * 0.9183) = 0.0183$$

!?!  
!?

Das três características que tivemos, o peso foi o melhor.

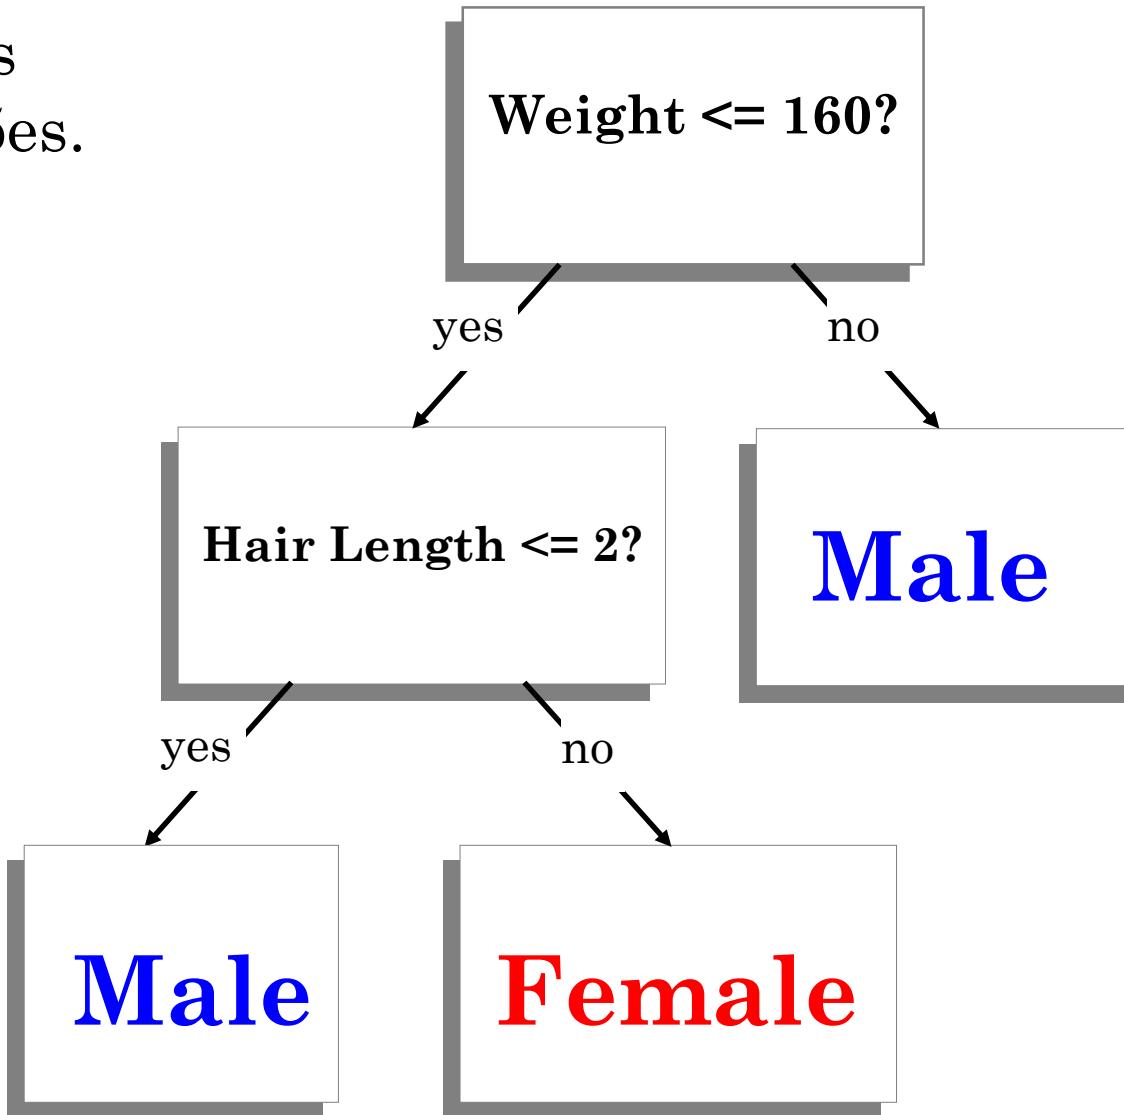
Mas enquanto as pessoas que pesam mais de 160 libras  
são perfeitamente classificadas (como homens), as pessoas  
com menos de 160 libras não são perfeitamente  
classificadas ... Então, usamos recursão!

- Veja que o comprimento do cabelo resolveu o problema.



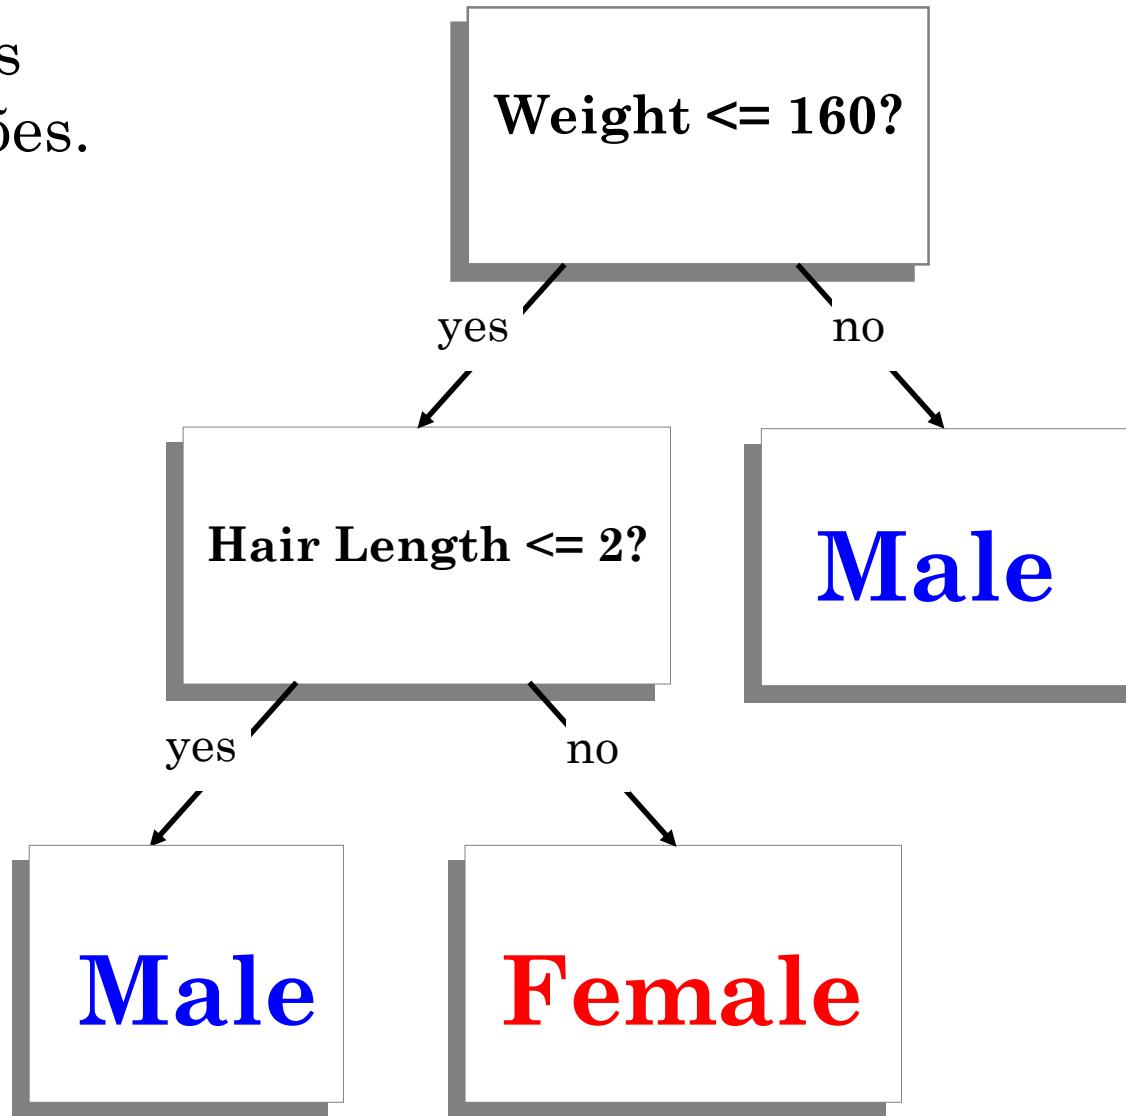
Não precisamos manter os dados, somente as condições.

Como estas pessoas seriam classificadas?



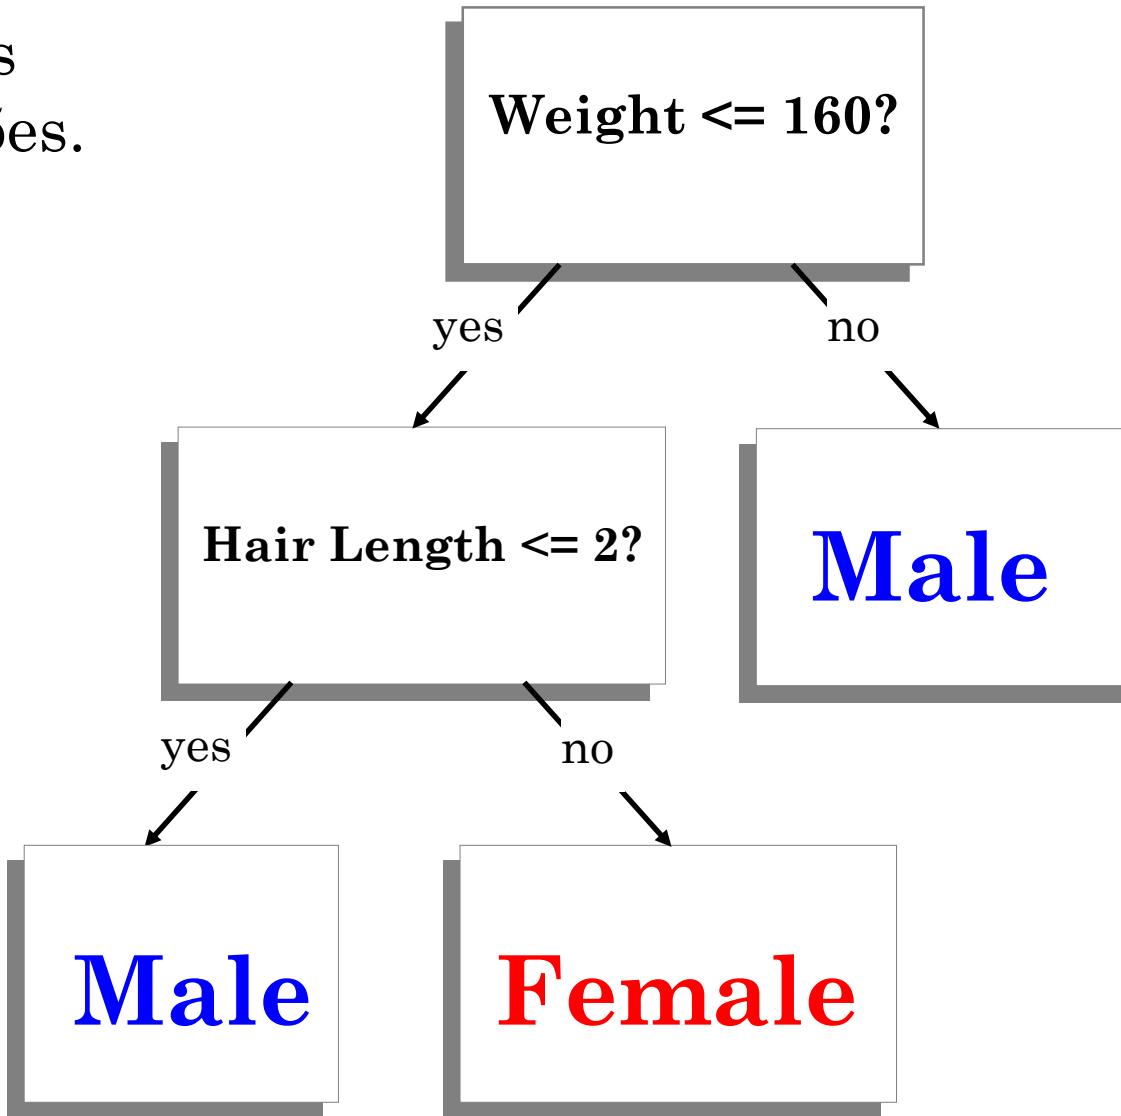
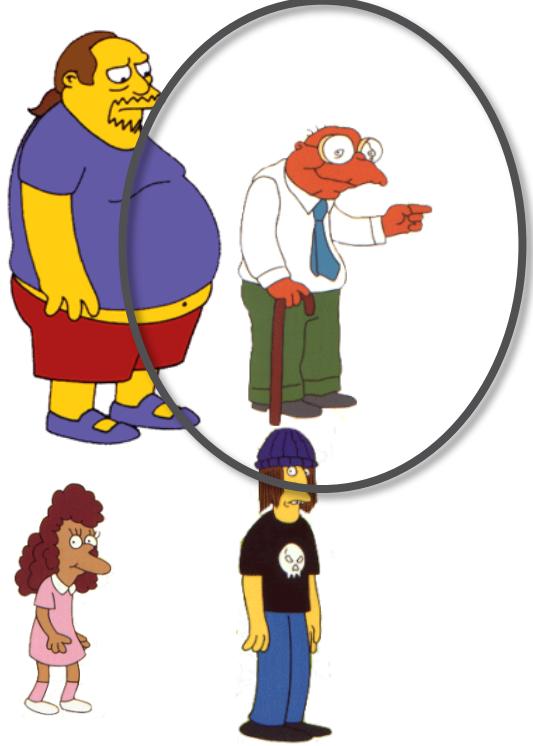
Não precisamos manter os dados, somente as condições.

Como estas pessoas seriam classificadas?



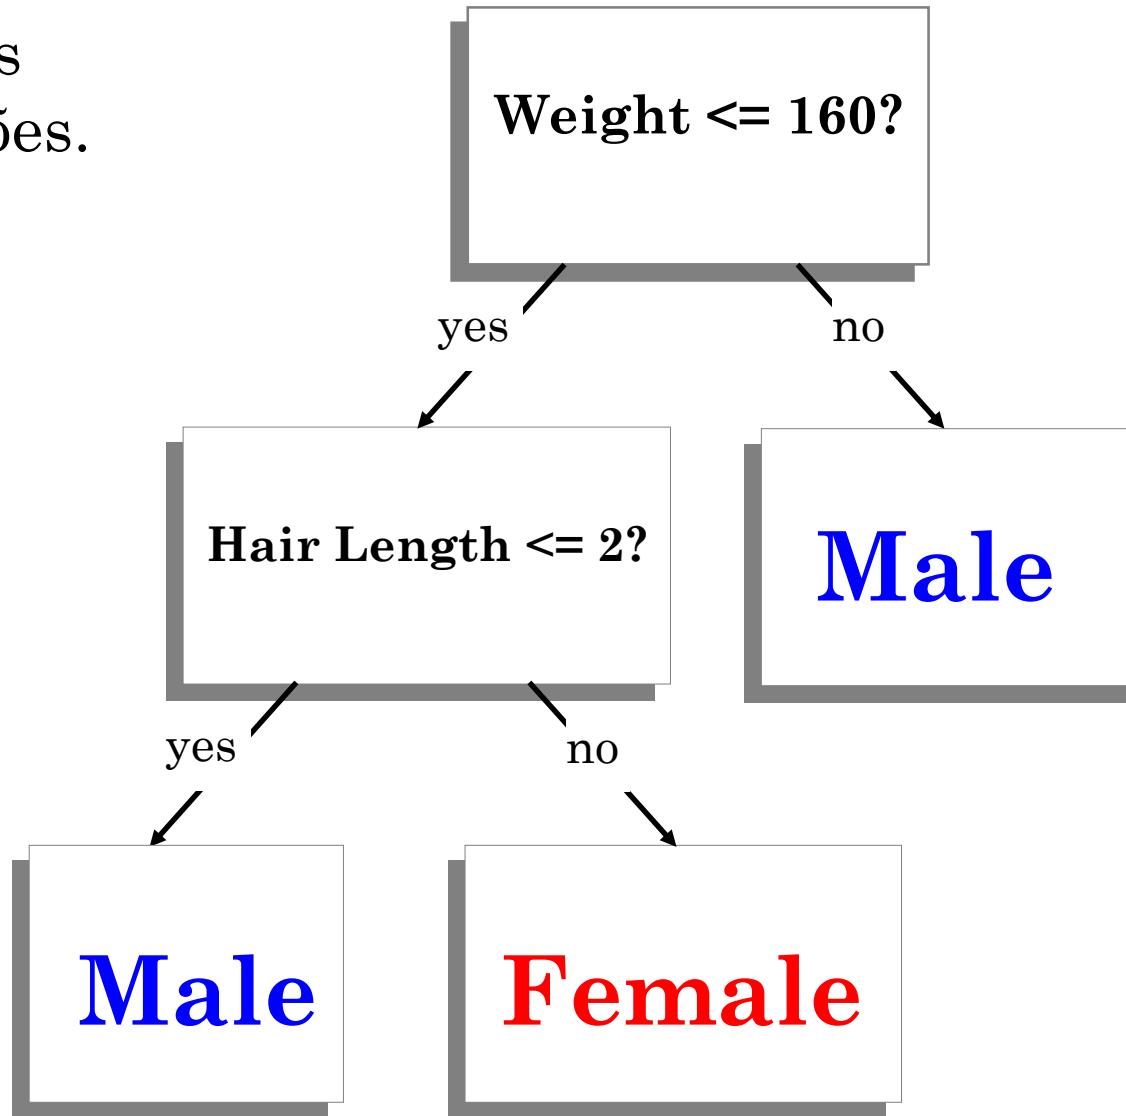
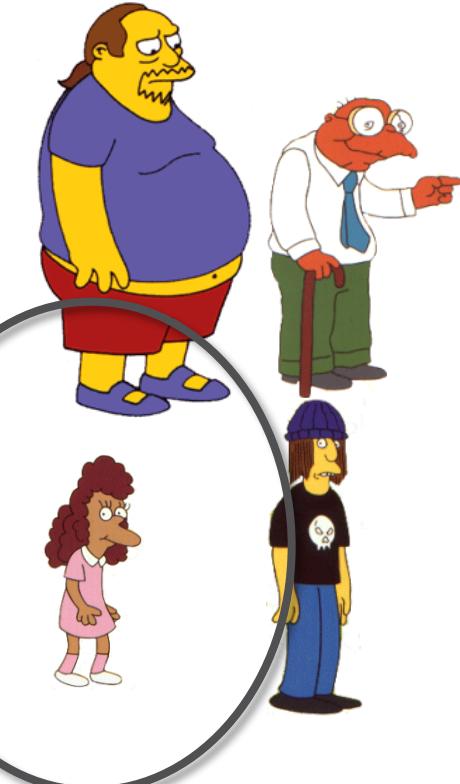
Não precisamos manter os dados, somente as condições.

Como estas pessoas seriam classificadas?



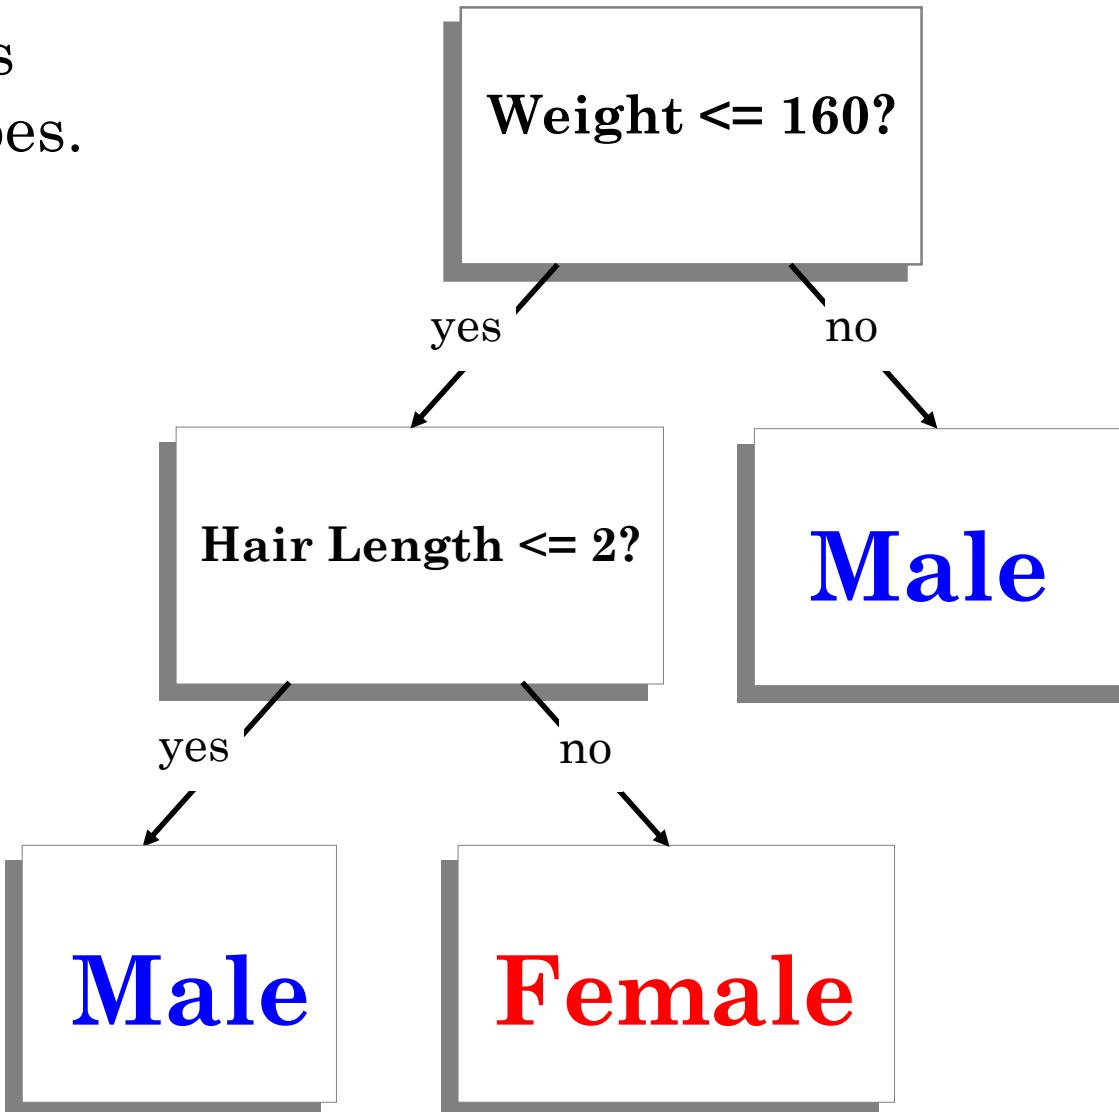
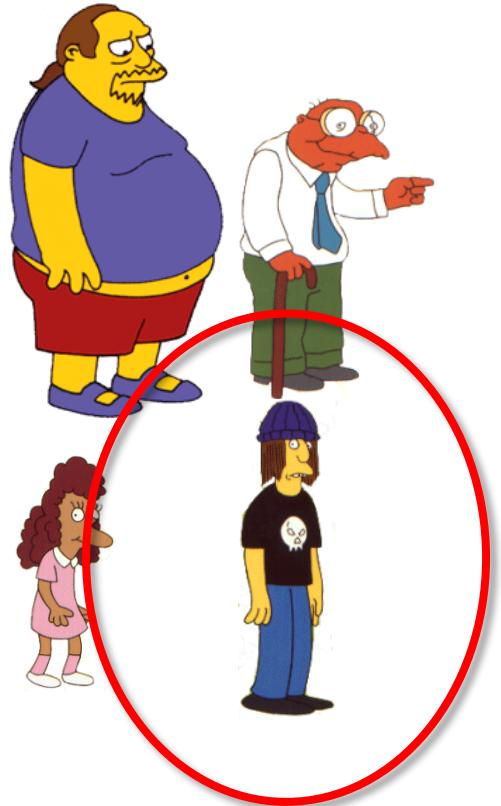
Não precisamos manter os dados, somente as condições.

Como estas pessoas seriam classificadas?



Não precisamos manter os dados, somente as condições.

Como estas pessoas seriam classificadas?



# *Hands On!*

1. Converta a seguinte árvore gerada um algoritmo para testar se o indivíduo  $X$  é homem ou mulher.
2. Calcule a entropia gerada por 35 instancias, onde 21 foram classificadas de um lado (19A e 2B) e 14 de outro (3A 11B).

